

2026 《人工智能导论》大作业

任务名称：可解释的谣言检测

完成组号： 6

小组人员：何泳逸、赵苗希、刘雨哲、杨乐彤

完成时间： 2026.6.21

1. 任务目标

本项目的核心目标是基于给定的社交媒体推文数据集，构建一个具备强泛化能力与高效运行时间的可解释谣言检测系统。具体任务要求如下：

1. 双分类预测：对输入的测试文本进行谣言检测，准确输出二进制分类（0 代表非谣言、1 代表谣言），且准确率越高越好。
2. 文本可解释性：针对分类结果，模型需同步输出一段富有逻辑的文本，详细解释其判断依据。
3. 符合复现规范：系统若涉及大语言模型开发，必须限定调用上海交通大学官方提供的模型接口，以确保学术可复现性。

2. 具体内容

（1）实施方案

为了探究不同复杂度模型在谣言检测与可解释性上的表现，本项目实现了两套对比方案：

方案一：基于统计特征的传统机器学习基准模型（Baseline）

- a. 流程：原始文本 → 文本预处理 → TF-IDF 向量化 → 逻辑回归分类器。
- b. 可解释性机制：属于内在可解释性。系统通过计算每个激活词的 $TF-IDF * w$ 乘积大小，直接提取对分类决策贡献最大的 Top-5 核心词作为证据链，再将其送入大模型生成最终解释。

方案二：基于深度语义与强思考大模型的复合模型（本项目核心方案）

- a. 流程：原始文本 -> 预训练模型微调 -> 分类结果与语义特征词提取 -> 提示词工程 -> 交大官方大模型接口（DeepSeek）。
- b. 可解释性机制：属于事后解释。利用微调后的 RoBERTa 提取深层语义关联的证据词，结合大模型的思维链推理能力，生成全方位的论证式文本依据。

（2）核心代码分析

a. 主流程解耦控制（main.py）

无论是主线模型还是对照模型，均采用高度解耦的模块化结构，将分类逻辑与可解释性逻辑分离：

```
10 def main():
11     text = input("Enter text: ")
12     results = run_inference([text])
13     for text, (label, conf, evidence) in zip([text], results):
14         print(f"[{label}] conf={conf:.3f} evidence={evidence}")
15         print(f"  text: {text[:80]}...")
16         explanation = explain(text, label, evidence)
17         if explanation:
18             print(f"  explanation: {explanation}")
19         print()
```

b. 校内大模型接口规范连接（llm/llm.py）

严格对接交大云端大模型，选用具备强推理能力的 deepseek-reasoner 模型，并将高随机性的 temperature 压低至 0.3，以确保原理解释的学术客观性，最大程度抑制大模型的“幻觉”现象：

```
class LLMConfig:
    """LLM API 配置"""

    api_key: str = "" # 通过环境变量 LLM_API_KEY 设置
    base_url: str = "https://models.sjtu.edu.cn/api/v1"
    model: str = "deepseek-reasoner"
    temperature: float = 0.3
    max_tokens: int = 512
    timeout: int = 30
```

(3) 检测结果分析（正确率等）

在通过 Canvas 下载的最终验证集 val.csv 上进行批量评估，两套方案的分类性能定量对比如下表所示：

模型方案	准确率 (Accuracy)	F1-Score
方案一：TF-IDF + LR (对照组)	0.8354	0.8059
方 案 二： Twitter-RoBERTa（主模型）	0.8928	0.8746

详细结果见下图：

方案一：TF-IDF + LR (对照组)

【分类准确率 (Accuracy)】： 0.8354				
【分类精确率 (Precision)】： 0.8303				
【分类召回率 (Recall)】： 0.7829				
【F1-Score (综合调和平均)】： 0.8059				

【分类结果详细报告 (Classification Report)】：				
	precision	recall	f1-score	support
Non-Rumor (0)	0.84	0.88	0.86	226
Rumor (1)	0.83	0.78	0.81	175
accuracy			0.84	401
macro avg	0.83	0.83	0.83	401
weighted avg	0.84	0.84	0.83	401
===== [Evaluation] 评测结束 =====				

方案二：Twitter-RoBERTa (主模型)

Accuracy:	0.8928			
F1:	0.8746			
Confusion Matrix:				
[[208 18]				
[25 150]]				
	precision	recall	f1-score	support
non-rumor	0.89	0.92	0.91	226
rumor	0.89	0.86	0.87	175
accuracy			0.89	401
macro avg	0.89	0.89	0.89	401
weighted avg	0.89	0.89	0.89	401

（4）判断依据的分析（可解释性等）

为进一步验证系统的“可解释性”表现，输入典型测试用例：“Breaking News: A massive UFO just landed in the middle of campus!”

方案一（逻辑回归）表现：

提取出的证据词为 ['UFO', 'massive', 'landed', 'Breaking']。其解释机制直接依赖于统计词频与权重的线性组合，虽然直观，但在处理隐喻或反讽等复杂文本时缺乏对整体语境的深层感知。

方案二（复合模型）表现：

模型分类输出为 [1]（谣言），置信度高达 0.928。交大接口的 deepseek-reasoner 深度给出了如下判断依据：

“该推文使用了‘Breaking News’这类煽动性标题，但内容缺乏任何可验证的来源或具体细节。提及‘UFO’和‘massive’等夸张词汇，试图引发情绪共鸣而非理性判断。此外，‘landed in the middle of campus’这一未经证实的说法极可能为虚假信息，符合谣言中夸大事实和制造恐

慌的典型特征。”

结论：方案二在可解释性上具备更高级的语义归纳能力，能够真正剖析出谣言的修辞手法和逻辑漏洞，可解释性质量极高。

3. 工作总结

(1) 分工协作情况

a.前期分工安排

刘雨哲：模型开发与训练，完成 0-1 分类，readme.md。

杨乐彤：数据清洗，模型评估。

赵苗希：撰写报告。

何泳逸：(RAG 检索)，调用 llm 对分类结果生成文字解释。

b.实际 GitHub 仓库贡献

刘雨哲(fengyu21): Twitter-RoBERTa 主模型，readme.md 撰写。

杨乐彤(yt712):清洗后的数据集，另一版 TF-IDF + Logistic Regression 代码。

赵苗希(chuatanya): TF-IDF + Logistic Regression 对照模型代码，实验报告。

何泳逸 (R1bosome-He): 判断依据生成模块，大语言模型接口整合，多模型权重投票机制。

(2) 收获、心得、遇到问题及解决思路

起初我们基于示例代码尝试调参和自建网络，但均未获突破，这暴露了我们对底层训练逻辑的理解不足。转变思路采用 RoBERTa 预训练模型微调后，验证集指标才取得显著提升。为进一步冲高

准确率，我们尝试将 RoBERTa、BiLSTM 与 TF-IDF 进行多数投票集成，结果却不升反降约 1%。后续剔除 TF-IDF，并对 RoBERTa 与 BiLSTM 采用 2:1 加权投票，才回升至单模型水平。这一曲折过程让我们深刻理解了模型特性与数据规模的匹配关系：RoBERTa 凭借海量预训练已编码语言模式，极小样本微调即可生效；而 BiLSTM 需从小样本从头学习，难以形成稳定语义表征；TF-IDF 更是完全缺失语序与语境信息。总之，在样本稀缺场景下，预训练模型优势极大；传统或轻量模型若未充分优化，盲目集成反而会引入噪声，拖累整体表现。

4. 课程建议

建议今后的课程中可以适当增加案例实操环节，搭配简单的代码演示或 AI 工具体验，方便同学们把理论知识落地理解。偶尔可以分享 AI 行业最新发展动态，拉近课本知识与当下技术的距离。